

UM ESTUDO DE REDES NEURAIIS ARTIFICIAIS DO TIPO PMC NA DETECÇÃO DE DEFEITOS NOS ROLAMENTOS DE MÁQUINAS DE INDUÇÃO

TIAGO DRUMMOND LOPES*, ALESSANDRO GOEDEL*, RODRIGO H. CUNHA PALÁCIOS*, WAGNER FONTES
GODOY*, CLAYTON LUIZ GRACIOLA*

**Universidade Tecnológica Federal do Paraná, Departamento de Engenharia Elétrica e Computação, Cornélio
Procópio, Paraná, Brasil*

Emails: tidrummond@gmail.com, agoedtel@utfpr.edu.br, rodrigopalacios@utfpr.edu.br,
wagnergodoy@utfpr.edu.br, claytongraciola@gmail.com

Abstract— The most commonly used electrical energy conversion element to mechanical is the three-phase induction motor, which is indispensable in industrial production processes, and it is constantly subject of research aiming to reduce maintenance and unscheduled downtime rates in the process. Major motors faults occurs in bearings. Intelligent systems are able of predicting faults in electric motors has been widely discussed in the literature. The purpose of this study is to perform a comparative study of artificial neural networks structures such as Multilayer Perceptron considering one and two hidden layers in order to find the most appropriate structure towards the application. Therefore, experimental results are presented from tests performed on a workbench with engines operating with defective bearings, under varied load conditions and voltage unbalance, allowing the analysis of the current signal in the time domain, tested under a wide range of neural topology.

Keywords— Three-phase Induction Motor, Bearing Fault Detection, Artificial Neural Networks, Current Sensor.

Resumo— O mais utilizado elemento de conversão de energia elétrica em mecânica motriz é o motor de indução trifásico, o qual é indispensável nos processos produtivos industriais, é constantemente alvo de pesquisas para diminuir as taxas de manutenções e paradas não programadas no processo. Grande parte dos defeitos em motores ocorre em rolamentos. Os sistemas inteligentes são capazes de prever os defeitos dos motores elétricos e têm sido amplamente abordados na literatura. A proposta desse trabalho consiste em realizar um estudo comparativo entre estruturas de redes neurais artificiais do tipo Perceptron Multicamadas com uma e duas camadas ocultas, a fim de encontrar a estrutura mais adequada perante a presente aplicação. Os resultados experimentais são apresentados a partir de ensaios realizados em bancada com motores operando com rolamentos defeituosos, em condições variadas de conjugado de carga e desequilíbrio de tensão, possibilitando a análise do sinal de corrente no domínio do tempo, testados sob ampla variação da topologia neural.

Palavras-chave— Motor de Indução Trifásico, Detecção de Falhas em Rolamentos, Redes Neurais Artificiais, Sensor de Corrente.

1 Introdução

A elevada eficiência, baixa manutenção e pequeno volume, em comparação com os demais motores, são as principais características que tornam o Motor de Indução Trifásico (MIT) tão atraente para a conversão de energia elétrica em energia mecânica motriz. Atualmente, esse tipo de motor é o mais utilizado dentre as máquinas elétricas presentes no mercado (Gonzalez et al., 2014; Popescu et al., 2013; Goedtel et al., 2013; Barzegaran et al., 2013).

Mesmo que essas máquinas habitualmente sejam bem construídas podem estar sujeitas a falhas geradas, por exemplo, a partir da umidade e poeira do ambiente, problemas de qualidade de energia elétrica, sobreaquecimento, etc. Estas falhas podem ser classificadas em dois grupos: falhas elétricas e falhas mecânicas. As falhas elétricas são destacadas devido aos problemas relativos ao enrolamento de estator, enrolamento de rotor, barras quebradas no rotor, anéis quebrados no rotor e conexões. Por outro lado, as falhas mecânicas podem ser oriundas de problemas de rolamentos, excentricidade, desgaste de acoplamento e desalinhamento (Bellini et al., 2008). Estudos detalhados apresentados por Zarei et al. (2014) e Bellini et al. (2008) mostram que entre os principais elemen-

tos deteriorados nos MITs estão os rolamentos com mais de 40% dos casos de falhas. Ainda segundo os autores, aproximadamente 30% das falhas são oriundas de problemas com o enrolamento do estator e aproximadamente 10% apresentam quebra nas barras de rotor. Estes defeitos mecânicos e elétricos podem ser verificados direta ou indiretamente por meio da leitura de uma das fases na corrente elétrica de alimentação ou pela tensão elétrica, monitoramento do campo eletromagnético, medidas de temperatura ou por outros parâmetros (Ghate and Dudul, 2010).

Torna-se, não só atrativa, mas necessária a identificação de falhas em máquinas elétricas, uma vez que tais defeitos causam prejuízos imponderáveis no ambiente industrial. Quando um motor começa a apresentar defeitos pode-se notar algumas alterações em seu funcionamento, como: variação na temperatura de operação, mudanças nos sinais associados às vibrações mecânicas, ruídos audíveis e alterações no campo eletromagnético, dentre outros. Deste modo, a interpretação dessas alterações de comportamento pode contribuir na árdua tarefa de detecção de defeitos ainda em fase de evolução. Assim, uma operação corretiva pode ser planejada de forma a atuar no processo reduzindo os impactos e evitando uma parada inesperada (Araújo et al., 2011).

Nos últimos anos, a academia e a indústria vêm mostrando grande interesse nos estudos e pesquisas relacionadas às mais variadas técnicas de detecção de defeitos em máquinas elétricas. Nesse meio, destaca-se a pesquisa realizada em Bellini et al. (2008). Este trabalho apresenta uma minuciosa investigação das técnicas de diagnóstico para máquinas elétricas com referência especial para máquinas de indução. Uma lista completa de referências é relatada e examinada, e atividades de pesquisa classificadas em quatro temas principais: i) falhas elétricas; ii) falhas mecânicas; iii) processamento de sinal para análise e monitoramento; e iv) inteligência artificial e técnicas de tomada de decisão.

Com técnicas que diferem da usada deste trabalho apresentado, pesquisas recentes de detecção de defeitos nos rolamentos de motores de indução são encontradas na literatura conforme os trabalhos de Leite et al. (2014) e Harlisca et al. (2013). O primeiro artigo demonstra a detecção de falha de rolamento de um MIT analisando o espectro da corrente do estator. Algoritmos baseados Spectral Kurtosis, Kurtogram rápido e o Kurtogram Wavelet, também são aplicados para melhorar a análise. Testes experimentais são realizados considerando as falhas em diferentes fases de evolução e os resultados são promissores. Já no segundo estudo, a detecção de três tipos de falhas de rolamentos por meio de processamento estatístico das medições de fluxo é detalhada. O método não invasivo desenvolvido requer apenas duas sondas simples e cálculos fáceis.

De forma mais específica, estudos recentes apresentados nos artigos Godoy et al. (2014), Gongora et al. (2013) e Refaat et al. (2013) se aproximam na aplicação de Redes Neurais Artificiais (RNA) para a identificação de falhas de rolamentos em MITs, análoga à técnica utilizada no presente artigo. Portanto, este trabalho propõe um estudo detalhado de estruturas neurais com a arquitetura Perceptron Multicamadas (PMC), aplicadas na detecção de defeitos no rolamento de MITs. As redes são alimentadas com sinais reais de corrente do estator da máquina oriundos de experimentos realizados em ambiente laboratorial. Desequilíbrios de tensão na alimentação da máquina, ampla variação do perfil de carga no eixo do motor e diversos defeitos nos rolamentos (defeitos nas pistas externa e interna, desgaste excessivo e descarga elétrica por meio de curto circuito) são considerados nos ensaios. O artigo está dividido nas seguintes seções: a Seção II descreve a arquitetura de rede utilizada na pesquisa; na Seção III é exibido o sistema proposto neste trabalho e na Seção IV são apresentados os resultados experimentais. Finalmente, na Seção V expõem-se as conclusões deste artigo.

2 Redes Neurais Artificiais Perceptron Multicamadas

Diversas topologias de RNAs são obtidas com base na estrutura do neurônio artificial, podendo ser classifi-

cadas como redes de camada única ou redes multicamadas. As RNAs do tipo PMC possuem uma estrutura característica, com no mínimo uma camada de neurônios intermediária (escondida), localizada entre a camada de entrada e a camada de saída. Desta forma, as redes PMC possuem, ao menos, duas camadas de neurônios, estando estes elementos distribuídos entre as camadas intermediárias e a camada de saída (Silva et al., 2010).

Outra característica marcante dessas redes é a elevada possibilidade de aplicação nos mais variados tipos de problemas relacionados com as mais distintas áreas de conhecimento, sendo também considerada uma das arquiteturas mais flexíveis quando levada em conta sua função. Segundo Silva et al. (2010), as principais áreas exploradas pelo método neural são relacionadas aos aproximadores universais de funções, reconhecimento de padrões, identificação e controle de processos, previsão de séries temporais e otimização de sistemas.

Estas redes têm apresentado sucesso na resolução de diversos problemas quando treinadas de maneira supervisionada, através do algoritmo de backpropagation (Haykin, 1998). No modo de treinamento supervisionado, os padrões de dados de entrada são apresentados à rede e as suas respectivas saídas são calculadas. A diferença entre a saída real e a saída estimada pela rede é utilizada como parâmetro para o ajuste dos pesos sinápticos. Esse processo se repete de forma cíclica até que o erro tenha um valor aceitável. No caso, o supervisor monitora a resposta da rede referente a um padrão de dados de entrada.

Os sinais são apresentados a cada entrada da rede e transmitidos, camada a camada, de forma a se propagarem sempre em direção à saída. As saídas de uma camada são, necessariamente, as próprias entradas da camada seguinte. De forma mais específica, a saída dos neurônios da primeira camada neural escondida é a própria entrada dos neurônios pertencentes à segunda camada neural escondida. Analogamente, as saídas da segunda camada neural escondida são as respectivas entradas dos neurônios pertencentes à sua camada neural de saída.

Por todo o exposto, o presente trabalho apresenta um estudo comparativo detalhado entre diversas estruturas de rede de uma e duas camadas neurais escondidas, onde o principal objetivo é apontar a melhor configuração de rede dentre as testadas para detectar defeitos no rolamento em MITs.

3 Aquisição e Tratamento de Dados

O proposta dessa pesquisa consiste em usar duas das três correntes do motor de indução trabalhando em condições de normalidade e com defeitos no rolamento, criar um banco de dados para alimentar uma RNA que indica se a máquina possui defeitos no rolamento. Para isso, dois motores do fabricante WEG, ambos de 1 cv e alto rendimento foram utilizados para realização dos ensaios, sendo o Motor 1 e o Mo-




Figura 1: Estrutura de ensaios

tor 2 com respectivos rendimentos de 80,5% e 82,6%. Essas máquinas operaram com rolamentos sadios e defeituosos, em condições de desequilíbrio de tensão e variação de carga aplicada no eixo do motor. Tal procedimento foi realizado em uma bancada, a qual visa emular o comportamento de um MIT frente a diferentes pontos de operação, e assim reproduzir as mesmas condições encontradas em ambiente industrial.

A estrutura de ensaios apresentada na Fig. 1 baseia-se em uma máquina de corrente contínua, um torquímetro girante, um quadro de acionamento de máquinas elétricas com variadores de tensão e sensores de efeito Hall de corrente.

O funcionamento da bancada resume-se em acoplar o Motor de Corrente Contínua (MCC) ao MIT, através do mesmo eixo. Assim, com o MCC ligado para operar como um Gerador de Corrente Contínua (GCC) é possível atuar na variação da tensão de campo, por meio de uma fonte de corrente contínua, e, conseqüentemente, obter variação no torque de carga do MIT. A energia gerada pelo GCC no processo é dissipada em uma carga resistiva ligada a armadura da máquina. O torquímetro é responsável por fornecer a velocidade e torque imposto ao MIT e os sensores de efeito Hall são utilizados para mensurar a corrente. O motor é submetido a diferentes tipos de alimentação através de variadores de tensão (Variacs) conectados diretamente à rede, para que sejam obtidos os diferentes pontos de operação da máquina.

Tal processo de aquisição e tratamento de dados inicia-se com os sensores de efeito hall aferindo os sinais senoidais de corrente da máquina. Para que os sinais possam ser armazenados em um microcomputador (PC), utiliza-se a placa de aquisição de dados (DAQ) da fabricante National Instruments modelo NI USB6221, que através de uma porta USB faz a comunicação entre os sensores de corrente e o PC. O software Matlab é encarregado de registrar os dados, organizá-los em matrizes e processá-los.

De modo a permitir que os sinais sejam observados pela rede neural no domínio do tempo prevê-se o tratamento dos dados baseado na técnica que encontra-se respaldada na proposta de (do Nasci-

mento et al., 2011), a qual utiliza este método para estimação dos valores de harmônicos presentes nos sinais senoidais de corrente elétrica de cargas não lineares. Recentemente, os trabalhos Palácios et al. (2014), Godoy et al. (2014), Gongora et al. (2013) e Broniera et al. (2013) também basearam-se na mesma técnica de pré-processamento apresentando resultados promissores.

Inicialmente, os sinais referentes a duas das três fases de correntes do motor são somados vetorialmente e em seguida o procedimento proposto por do Nascimento et al. (2011) é aplicado. Esse processo consiste em discretizar o sinal com o objetivo de reduzir o número de amostras por semi ciclo. No caso deste trabalho foi sub-amostrado em 10, 25 e 50 pontos por semiciclo. Para simplificar a aplicação da rede neural, usa-se o módulo do sinal, evitando valores negativos. Na sequência do processamento, ocorre normalização pelo valor de pico de cada sinal amostrado, ou seja, os valores ficam no intervalo de zero a um. Por fim, as matrizes a serem apresentadas como entradas das RNAs são construídas.

A fim de obter sinais de corrente de MIT com rolamentos defeituosos, pares de rolamentos novos foram submetidos a condições que os tornassem falhos. Quatro tipos de defeitos foram recriados de forma controlada, tais como: defeito na pista externa, falha na pista interna, curto circuito e desgaste excessivo.

4 Resultados Experimentais

Essa seção apresenta os resultados experimentais deste trabalho, o qual visa investigar qual a melhor estrutura de rede neural artificial do tipo PMC, seja ela de uma ou duas camadas neurais escondidas, para detectar falhas de rolamento em MITs.

Para obter a classificação quanto ao funcionamento adequado do rolamento, foram amostrados os sinais das correntes trifásicas dos MITs em análise. Para tanto, foram separados os dados para as construções dos modelos inteligentes. Salienta-se que as amostras são sinais dos MITs em regime permanente, adquiridas em ensaios na bancada experimental, com conjugado de carga variando de 0,5 a 6 Nm e com 16 combinações de desequilíbrio de tensão entre as fases, considerando o limite máximo de $\pm 10\%$. A partir dessas características construiu-se um banco de dados de 275 ensaios, sendo que em 102 experimentos o motor operou com rolamentos saudáveis e em 173 defeituosos.

Todas as RNAs presentes no estudo são do tipo PMC, a função de ativação das camadas intermediárias é do tipo tangente hiperbólica e da camada de saída é do tipo linear. A taxa de aprendizado foi de 0,3, o termo momentum foi fixado em 0,2 e o número de épocas para convergência igual a 500. O algoritmo backpropagation foi escolhido para realizar o treinamento e usou-se a validação cruzada com 10 partições. As redes foram alimentadas com 10, 25 e 50 entradas. Para estruturas neurais com uma

camada escondida a quantidade de neurônios variou no intervalo de 1 a 30, já para estruturas com duas camadas ocultas variou-se o número de neurônios de 5 a 15 para ambas as camadas. Tendo em vista todas as combinações, treinou-se um total de 453 redes.

A Tabela 1 apresenta os resultados percentuais de acerto das redes com estrutura neural de apenas uma camada escondida, onde testou-se desde a estrutura mínima, ou seja, apenas 1 neurônio na camada intermediária e incrementou-se até atingir a marca de 30 neurônios. Dessa forma foram treinadas e validadas 90 RNAs.

Tabela 1: Acurácia para estruturas neurais com uma camada oculta

10 Entradas		25 Entradas		50 Entradas	
N	A (%)	N	A (%)	N	A (%)
1	72,61	1	73,33	1	73,58
2	77,33	2	78,06	2	77,21
3	79,88	3	81,70	3	80,24
4	80,36	4	83,15	4	80,85
5	84,85	5	86,67	5	84,61
6	87,03	6	87,76	6	84,24
7	89,33	7	89,21	7	86,06
8	88,48	8	91,64	8	88,00
9	87,03	9	91,03	9	89,33
10	88,24	10	89,09	10	90,67
11	89,82	11	92,00	11	89,58
12	89,33	12	92,12	12	90,42
13	89,09	13	91,52	13	91,03
14	90,06	14	93,09	14	91,88
15	92,00	15	92,97	15	92,36
16	89,82	16	92,24	16	94,79
17	91,03	17	92,85	17	91,76
18	89,81	18	93,09	18	92,85
19	90,55	19	93,45	19	93,09
20	90,55	20	93,21	20	93,21
21	88,61	21	93,70	21	92,97
22	91,15	22	92,73	22	94,18
23	90,30	23	93,94	23	93,70
24	90,42	24	94,06	24	93,09
25	90,91	25	94,19	25	94,67
26	92,61	26	92,97	26	93,70
27	90,67	27	94,79	27	94,30
28	91,27	28	93,33	28	93,45
29	89,94	29	93,82	29	93,82
30	90,42	30	94,55	30	93,09

N = número de neurônios na camada oculta
A = acurácia das estruturas neurais

As Figs. 2, 3 e 4 representam graficamente a acurácia das redes com 10, 25 e 50 entradas respectivamente. Pode-se observar na Fig. 2 que a estrutura de rede mais simples, ou seja, com apenas 1 neurônio na camada oculta apresentou percentual de acerto de 72,61%, enquanto que a maior acurácia foi alcançada com 26 neurônios na camada intermediária atingindo 92,61%. Já a Fig. 3 mostra que a menor taxa de acerto atingida foi de 73,33% para 1 neurônio na camada escondida, porém com 24, 25, 27 e 30 neurônios ultrapassaram a marca de 94%. A Fig. 4 expõe margens de acerto mínima de 73,58% e máxima de 94,79% para redes estruturadas com, respectivamente, 1 e 16 neurônios na camada oculta.

As Tabelas 2, 3 e 4 apresentam, respectivamente, os resultados percentuais de acerto das redes de estrutura neural constituídas de duas camadas escondidas e 10, 25 e 50 entradas, onde variou-se a quantidade de neurônios no intervalo de 5 a 15 em ambas as camadas ocultas. Com isso obteve-se um total de 363




Figura 2: Acurácia para estruturas neurais com uma camada oculta e 10 entradas




Figura 3: Acurácia para estruturas neurais com uma camada oculta e 25 entradas




Figura 4: Acurácia para estruturas neurais com uma camada oculta e 50 entradas

RNAs.

Pode-se observar na Tabela 2 que a estrutura de rede com configuração 6-9, ou seja, com 6 neurônios na primeira camada oculta e 9 na segunda apresentou percentual de acerto de 80,36%, enquanto que a maior acurácia foi alcançada com 14 neurônios na primeira camada intermediária e 15 na segunda atingindo 89,70%. Já a Tabela 3 mostra que a menor taxa de acerto atingida foi de 80,97% para configuração 6-14, porém com configuração 13-12 igualou a marca de 93,09%. A Tabela 4 expõe margens de acerto mínima de 79,76% e máxima de 93,70% para redes com configuração 5-10 e 14-13, respectivamente.

De forma generalista, a rede de estrutura mais simples, com apenas 1 neurônio na camada oculta e 10 entradas, obteve a menor taxa de acerto percentual (72,71%), que não é considerada desprezível, pois essa estrutura neural possui um baixíssimo custo computacional para ser treinada, validada e operada. Além de ser utilizada como ferramenta auxiliar na tomada de decisão. Por outro lado, a rede com 27

Tabela 2: Acurácia para estruturas neurais com duas camadas ocultas e 10 entradas

1ª Camada	5	6	7	8	9	10	11	12	13	14	15
2ª Camada	Acurácia (%)										
5	82,91	84,12	83,64	85,09	86,30	86,67	85,94	84,85	87,27	87,03	87,39
6	81,70	82,67	85,58	85,45	85,58	87,88	86,55	87,15	88,12	85,33	86,55
7	81,82	84,12	84,36	87,39	86,42	88,73	86,79	85,94	88,24	87,64	87,15
8	81,45	83,03	83,03	85,70	84,61	84,85	84,00	84,73	87,39	89,45	86,06
9	82,18	80,36	81,09	86,42	85,09	86,91	86,79	87,76	89,33	85,58	86,79
10	82,55	83,15	82,42	85,09	85,82	84,48	86,91	88,00	89,45	87,03	86,91
11	81,82	80,36	84,61	82,18	85,09	83,27	85,33	84,97	87,76	87,52	86,67
12	80,36	82,67	80,61	85,58	83,88	84,97	86,67	88,61	87,15	86,42	85,21
13	82,18	84,12	83,15	83,27	85,21	87,15	87,15	84,36	89,45	87,03	86,30
14	81,21	81,70	82,55	85,45	86,42	84,85	86,79	86,55	87,64	87,76	88,36
15	81,58	82,79	84,73	85,33	84,97	87,52	84,97	87,03	88,00	89,70	84,97

Tabela 3: Acurácia para estruturas neurais com duas camadas ocultas e 25 entradas

1ª Camada	5	6	7	8	9	10	11	12	13	14	15
2ª Camada	Acurácia (%)										
5	82,91	84,85	84,00	85,94	85,09	89,70	89,58	91,27	88,24	88,24	91,15
6	81,45	85,45	84,00	86,67	87,03	87,76	88,61	91,64	90,67	87,52	89,94
7	81,82	83,76	84,97	85,45	87,15	88,85	91,76	88,85	90,91	89,82	89,21
8	83,52	82,67	84,85	85,70	84,73	88,12	87,03	90,18	90,55	91,52	91,52
9	81,82	82,30	85,21	87,15	89,21	87,15	92,00	89,70	89,70	91,39	91,15
10	82,18	84,36	84,00	85,58	87,03	88,97	89,45	91,64	89,94	91,27	92,73
11	82,91	83,76	86,67	88,12	86,67	90,67	89,33	89,94	87,27	91,15	90,67
12	81,21	82,42	87,27	88,00	87,88	88,00	89,94	90,06	93,09	90,91	90,55
13	81,94	83,64	84,97	87,15	86,42	88,73	91,03	90,06	91,39	92,00	91,15
14	83,39	80,97	84,85	86,91	89,09	88,97	90,18	92,24	92,73	91,88	91,39
15	82,91	82,42	85,82	87,15	86,67	86,67	89,33	89,70	91,52	92,24	92,00

Tabela 4: Acurácia para estruturas neurais com duas camadas ocultas e 50 entradas

1ª Camada	5	6	7	8	9	10	11	12	13	14	15
2ª Camada	Acurácia (%)										
5	82,06	84,73	85,58	86,42	87,88	90,30	91,76	89,58	88,24	87,03	89,33
6	83,52	85,82	86,67	87,76	88,00	89,33	90,06	90,55	90,30	92,36	89,58
7	81,09	84,85	85,45	87,76	87,76	87,52	89,70	90,55	90,55	90,67	91,03
8	83,52	84,73	86,06	85,82	89,94	90,91	90,30	90,42	92,73	90,67	92,97
9	80,85	83,88	85,21	85,21	89,09	87,52	89,94	90,79	91,27	91,76	91,76
10	79,76	84,12	86,06	87,39	88,12	88,36	89,33	91,15	89,94	89,82	92,61
11	81,21	84,00	87,88	87,52	89,21	88,48	90,67	90,42	91,39	90,72	92,85
12	80,73	83,39	85,94	88,97	87,64	88,36	90,30	90,06	92,00	91,76	91,76
13	82,42	84,97	87,03	86,18	85,33	90,67	89,33	87,76	91,27	93,70	92,61
14	81,82	85,33	87,27	89,58	89,70	87,15	91,27	90,55	92,36	91,03	90,79
15	82,42	84,85	86,55	88,61	89,09	89,58	87,27	90,67	93,33	92,73	91,15

neurônios na camada escondida e 25 entradas se mostrou como a estrutura mais precisa entre as testadas, alcançando a marca de 94,79% de acerto.

5 Conclusão

No presente trabalho foi exposto um estudo comparativo entre estruturas de RNAs do tipo PMC de uma e duas camadas escondidas. Essas redes foram usadas para detectar defeitos no rolamento em MITs.

Sinais de corrente de dois motores de 1 cv operando com rolamentos saudáveis e defeituosos foram coletados em experimentos realizados em laboratório.

Os sinais referentes a duas das três correntes do motor são somados, discretizados em 10, 25 e 50 pontos por semiciclo e normalizados em função do valor máximo. Assim sendo, as matrizes que alimentam a entrada das redes PMC são criadas. Essas redes são usadas como ferramenta auxiliar para diagnóstico de defeitos nos rolamentos dos MITs.

No estudo, percebe-se que as estruturas com apenas uma camada oculta se mostraram mais precisas na identificação de rolamentos defeituosos quando comparadas às estruturas de dupla camada escon-

dida. A rede de estrutura mais simples, com apenas 1 neurônio na camada oculta e 10 entradas, obteve a menor taxa de acerto percentual (72,71%). Contudo, a rede com 27 neurônios na camada escondida e 25 entradas alcançou a maior taxa de acerto (94,79%) dentre as estruturas testadas.

Um fator o qual deve ser levado em conta em muitas aplicações de RNAs é o custo computacional do algoritmo em questão. Dessa forma, algumas outras estruturas se tornam atraente, como é o exemplo da estrutura com apenas um neurônio e 10 entradas. Embora sua acurácia seja de 72,71%, não é considerada desprezível, pois essa estrutura neural possui um baixíssimo custo computacional para ser treinada, validada e operada. Nesse sentido, outras estruturas podem ser relacionadas como as com 4, 5, 6 e 7 neurônios na camada intermediária e 10 entradas, as quais possuem percentual de acerto acima de 80%. Outra estrutura que se destacou é a composta por 25 neurônios na camada intermediária com 25 entradas, pois atingiu 94,19% de taxa de acerto, perfazendo um decréscimo de apenas 0,60% perante a rede mais precisa. À vista disso, cabe ao usuário da ferramenta em questão escolher perante à sua necessidade qual a

estrutura neural mais adequada.

Constatou-se que estruturas de duas camadas ocultas não são muito atraentes para tal aplicação, visto que além de se mostrarem menos precisas, ainda possuem maior custo computacional quando comparadas as redes de apenas uma camada escondida.

Agradecimentos

Os autores agradecem o apoio da Fundação Araucária (Processo N° 06/56093-3) e do CNPq (Processo N°474290/2008-5, 473576/2011-2, 552269/2011-5).

Referências

- Araújo, R., Rodrigues, R., de Paula, H. and Bacarini, L. (2011). Premature wear and recurring bearing failures in three-phase induction motors: A case study, *IEEE Latin America Transactions* **9**(4): 528–533.
- Barzegaran, M., Mazloomzadeh, A. and Mohamed, O. (2013). Fault diagnosis of the asynchronous machines through magnetic signature analysis using finite-element method and neural networks, *IEEE Transactions on Energy Conversion* **28**(4): 1064–1071.
- Bellini, A., Filippetti, F., Tassoni, C. and Capolino, G. A. (2008). Advances in diagnostic techniques for induction machines, *IEEE Transactions on Industrial Electronics* **55**(12): 4109–4126.
- Broniera, P., Gongora, W., Goedtel, A. and Godoy, W. (2013). Diagnosis of stator winding interturn short circuit in three-phase induction motors by using artificial neural networks, *2013 IEEE International Symposium on Diagnostics for Electric Machines, Power Electronics and Drives (SDEMPED)*, pp. 281–287.
- do Nascimento, C. F., de Oliveira Jr, A. A., Goedtel, A. and Serni, P. J. A. (2011). Harmonic identification using parallel neural networks in single-phase systems, *Applied Soft Computing* **11**(2): 2178–2185.
- Ghate, V. N. and Dudul, S. V. (2010). Optimal mlp neural network classifier for fault detection of three phase induction motor, *Expert Systems with Applications* **37**(1): 3468–3481.
- Godoy, W., da Silva, I., Goedtel, A., Palacios, R. and Gongora, W. (2014). Neural approach for bearing fault classification in induction motors by using motor current and voltage, *2014 International Joint Conference on Neural Networks (IJCNN)*, pp. 2087–2092.
- Goedtel, A., Nunes da Silva, I., Amaral Serni, P., Suetake, M., Francisco do Nascimento, C. and Oliveira da Silva, S. (2013). Speed estimation for induction motor using neural networks method, *IEEE Latin America Transactions* **11**(2): 768–778.
- Gongora, W., Silva, H., Goedtel, A., Godoy, W. and da Silva, S. (2013). Neural approach for bearing fault detection in three phase induction motors, *2013 IEEE International Symposium on Diagnostics for Electric Machines, Power Electronics and Drives (SDEMPED)*, pp. 566–572.
- Gonzalez, A., Hernandez, C. and Arjona, M. (2014). A novel high-efficiency parallel-winding connection for a three-phase induction motor fed by a single-phase power supply, *IEEE Transactions on Energy Conversion* **29**(2): 269–277.
- Harlisca, C., Szabo, L., Frosini, L. and Albini, A. (2013). Bearing faults detection in induction machines based on statistical processing of the stray fluxes measurements, *2013 IEEE International Symposium on Diagnostics for Electric Machines, Power Electronics and Drives (SDEMPED)*, pp. 371–376.
- Haykin, S. (1998). *Neural Networks: A Comprehensive Foundation*, 2nd edn, Prentice Hall PTR, Upper Saddle River, NJ, USA.
- Leite, V., Borges da Silva, J., Veloso, G., Da Silva, L., Lambert-Torres, G., Bonaldi, E. and de Oliveira, L. (2014). Detection of localized bearing faults in induction machines by spectral kurtosis and envelope analysis of stator current, *IEEE Transactions on Industrial Electronics* **PP**(99): 1–1.
- Palácios, R. H. C., Silva, I. N., Goedtel, A., Godoy, W. F. and Oleskovicz, M. (2014). A robust neural method to estimate torque in three-phase induction motor, *Journal of Control, Automation and Electrical Systems* pp. 1–10.
- Popescu, M., Dorrell, D., Alberti, L., Bianchi, N., Staton, D. and Hawkins, D. (2013). Thermal analysis of duplex three-phase induction motor under fault operating conditions, *IEEE Transactions on Industry Applications* **49**(4): 1523–1530.
- Refaat, S., Abu-Rub, H., Saad, M., Aboul-Zahab, E. and Iqbal, A. (2013). Ann-based for detection, diagnosis the bearing fault for three phase induction motors using current signal, *2013 IEEE International Conference on Industrial Technology (ICIT)*, pp. 253–258.
- Silva, I. N., Spatti, D. H. and Flauzino, R. A. (2010). *Artificial Neural Networks for Engineering and Applied Sciences (in Portuguese)*, ArtLiber, São Paulo.
- Zarei, J., Tajeddini, M. A. and Karimi, H. R. (2014). Vibration analysis for bearing fault detection and classification using an intelligent filter, *Mechatronics* **24**(2): 151 – 157.