

O Básico sobre Matrizes e Modelos Lineares

Prof. Rafael Tassinari Resende (PPGGMP/UFG) | 2024.

Capítulo 1. Matrizes

Multiplicação de Matrizes

A multiplicação de matrizes é uma operação fundamental na álgebra linear, com aplicações em várias áreas, incluindo estatística, engenharia, computação, entre outras. Não abordarei soma e subtração de matrizes, pois são conceitos bastante intuitivos. Sobre a multiplicação, vamos entender alguns conceitos e ver exemplos.

Regras Básicas para Multiplicação de Matrizes

- Dimensões Compatíveis:** Para que duas matrizes A e B possam ser multiplicadas, o número de colunas de A deve ser igual ao número de linhas de B . Se A é uma matriz de dimensão $m \times n$ (m linhas e n colunas) e B é uma matriz de dimensão $n \times p$ (n linhas e p colunas), então o produto AB será uma matriz de dimensão $m \times p$. Se o produto entre duas matrizes existe, estas matrizes são chamadas de **conformáveis**, caso contrário, são chamadas de **não-conformáveis**;
- Em matrizes, a ordem dos fatores pode alterar o produto! Isto é, nem sempre $AB = BA$, pois a multiplicação de matrizes não é comutativa em geral. No entanto, essa igualdade pode ocorrer em casos especiais, como quando as matrizes são diagonais, escalares, incluem a matriz identidade, ou em casos específicos de matrizes simétricas que comutam;
- Cálculo dos Elementos da Matriz Resultante:** O elemento na posição (i, j) da matriz resultante $C = AB$ é obtido pela soma do produto dos elementos da i -ésima linha de A pelos elementos correspondentes da j -ésima coluna de B :

$$C_{ij} = \sum_{k=1}^n A_{ik} \times B_{kj}$$

Exemplo 1: Multiplicação de Duas Matrizes 2×2

Considere as matrizes A e B : $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$, $B = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$, para encontrar o produto AB :

$AB = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}$, calculemos os elementos de AB :

$$C_{11} = 1 \times 5 + 2 \times 7 = 5 + 14 = 19,$$

$$C_{12} = 1 \times 6 + 2 \times 8 = 6 + 16 = 22,$$

$$C_{21} = 3 \times 5 + 4 \times 7 = 15 + 28 = 43,$$

$$C_{22} = 3 \times 6 + 4 \times 8 = 18 + 32 = 50.$$

Portanto,

$$AB = \begin{bmatrix} 19 & 22 \\ 43 & 50 \end{bmatrix}.$$

Exemplo 2: Multiplicação de uma Matriz 2×3 por uma Matriz 3×2 .

Considere as matrizes A e B :

$$A = \begin{bmatrix} 1 & 4 & 2 \\ 3 & 0 & 5 \end{bmatrix}, B = \begin{bmatrix} 2 & 3 \\ 1 & 4 \\ 0 & 6 \end{bmatrix}, \text{ para encontrar o produto } AB:$$

$$AB = \begin{bmatrix} 1 & 4 & 2 \\ 3 & 0 & 5 \end{bmatrix} \begin{bmatrix} 2 & 3 \\ 1 & 4 \\ 0 & 6 \end{bmatrix}, \text{ calculemos os elementos de } AB:$$

$$C_{11} = 1 \times 2 + 4 \times 1 + 2 \times 0 = 2 + 4 + 0 = 6,$$

$$C_{12} = 1 \times 3 + 4 \times 4 + 2 \times 6 = 3 + 16 + 12 = 31,$$

$$C_{21} = 3 \times 2 + 0 \times 1 + 5 \times 0 = 6 + 0 + 0 = 6,$$

$$C_{22} = 3 \times 3 + 0 \times 4 + 5 \times 6 = 9 + 0 + 30 = 39.$$

Portanto,

$$AB = \begin{bmatrix} 6 & 31 \\ 6 & 39 \end{bmatrix}.$$

Matrizes Transpostas

A matriz transposta é uma operação que transforma uma matriz trocando suas linhas por colunas. Se temos uma matriz A de dimensão $m \times n$, sua transposta, denotada por A^T ou simplesmente A' , será uma matriz de dimensão $n \times m$. Isso significa que o elemento na posição (i, j) da matriz original A se torna o elemento na posição (j, i) na matriz transposta A' .

Exemplo:

Considere a matriz A de dimensão 3×2 :

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 3 \\ 1 & 5 \end{bmatrix}$$

A transposta de A , denotada por A' , será:

$$A' = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 3 & 5 \end{bmatrix}$$

Aqui, a primeira linha da matriz original A se torna a primeira coluna de A' , a segunda linha de A se torna a segunda coluna de A' , e assim por diante. Se uma matriz B é igual a sua inversa B' , ela é chamada **simétrica**. Matrizes simétricas são sempre quadradas. Matrizes de covariâncias ou de correlações sempre serão simétricas.

Propriedades da Matriz Transposta

- $(A')' = A$: A transposta da transposta de uma matriz é a própria matriz original.
- $(A + B)' = A' + B'$: A transposta da soma de duas matrizes é igual à soma das transpostas das matrizes.
- $(AB)' = B'A'$: A transposta do produto de duas matrizes é igual ao produto das transpostas, com a ordem dos fatores invertida.

Matrizes Quadradas

Uma matriz quadrada é uma matriz que possui o mesmo número de linhas e colunas, ou seja, sua dimensão é $n \times n$, onde n é um número inteiro positivo. Essa característica permite operações matemáticas específicas, como determinantes, inversas e decomposições matriciais, essenciais na álgebra linear para representar transformações lineares invertíveis e resolver sistemas de equações. Conceitos importantes como matriz identidade, diagonal e simétrica são sempre quadradas. Por exemplo, uma matriz quadrada $A_{3 \times 3}$ seria representada como mostrado abaixo, onde cada a_{ij} representa um elemento da matriz.

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

Matriz Identidade (I)

Uma matriz identidade é uma matriz quadrada que possui 1's na diagonal principal (que vai do canto superior esquerdo ao canto inferior direito) e 0's em todas as outras posições. A matriz identidade de ordem n é denotada por I_n e tem a propriedade especial de que qualquer matriz A multiplicada pela identidade I resulta na própria matriz A (ou seja, $AI = IA = A$). Essa propriedade faz da matriz identidade o elemento neutro da multiplicação de matrizes, desempenhando um papel similar ao número 1 na multiplicação de números reais.

Exemplo:

$$I_3 = I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Matriz Diagonal (D)

Uma matriz diagonal é uma matriz quadrada na qual todos os elementos fora da diagonal principal são zero. A diagonal principal consiste nos elementos que vão do canto superior esquerdo ao canto inferior direito. Matematicamente, uma matriz diagonal D pode ser representada como $D_{ij} = 0 \forall i \neq j$. Os elementos na diagonal principal podem ser diferentes de zero e são os únicos elementos não nulos na matriz. As matrizes diagonais são importantes porque são simples de manipular e suas propriedades facilitam muitos cálculos matemáticos, como a multiplicação de matrizes e a determinação de inversas, já que a inversa de uma matriz diagonal (se todos os elementos da diagonal principal são diferentes de zero) é simplesmente outra matriz diagonal com os recíprocos dos elementos da diagonal original. Por **exemplo**, a matriz D abaixo é uma matriz diagonal, onde os elementos 3, 5 e 7 estão na diagonal principal e todos os outros elementos são zero.

$$D = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 7 \end{bmatrix}$$

Matrizes Bloco-Diagonal

São matrizes que possuem blocos ao longo da diagonal principal, enquanto todos os elementos que estão fora desses blocos são zero. Esses blocos não precisam ser necessariamente quadrados; podem ter diferentes dimensões, desde que a estrutura geral da matriz mantenha blocos ao longo da diagonal principal. Essas matrizes são úteis em várias áreas, especialmente em problemas de decomposição e simplificação de sistemas lineares, pois permitem que grandes matrizes sejam divididas em blocos menores e mais gerenciáveis. Matrizes bloco diagonal podem ser:

Exemplo 1:

$$B = \begin{bmatrix} B_1 & 0 \\ 0 & B_2 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 0 & 0 \\ 3 & 4 & 0 & 0 \\ 0 & 0 & 2 & 3 \\ 0 & 0 & 4 & 7 \end{bmatrix}, \text{ onde: } B_1 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \text{ e } B_2 = \begin{bmatrix} 2 & 3 \\ 4 & 7 \end{bmatrix}.$$

Exemplo 2.1:

$$Z = \begin{bmatrix} Z_1 & 0 & 0 \\ 0 & Z_2 & 0 \\ 0 & 0 & Z_3 \end{bmatrix} = \begin{bmatrix} 1 & -1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & -2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 & 1 & 1 \end{bmatrix}, \text{ onde: } Z_1 = \begin{bmatrix} 1 & -1 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, Z_2 = [1 \quad 2], \text{ e } Z_3 = \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

Exemplo 2.2:

$$Z = \begin{bmatrix} Z_1 & 0 & 0 \\ 0 & Z_2 & 0 \\ 0 & 0 & Z_3 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix}, \text{ onde: } Z_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, Z_2 = [1], \text{ e } Z_3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Inversa de Matrizes

A inversa de uma matriz A é uma matriz A^{-1} que, quando multiplicada pela matriz original, resulta na matriz identidade ($AA^{-1} = A^{-1}A = I$). Para que uma matriz tenha uma inversa, ela deve ser quadrada (mesmo número de linhas e colunas) e ter um determinante diferente de zero. O **determinante** de uma matriz é um valor escalar, único, que fornece informações sobre as propriedades da matriz, e é calculado a partir dos elementos da matriz seguindo regras específicas. Quando uma matriz não possui inversa, ela é chamada de matriz **singular**. A matriz inversa é útil em diversas aplicações, como na resolução de sistemas de equações lineares.

Além das inversas tradicionais, existem as inversas generalizadas, como a pseudoinversa de *Moore-Penrose*, denotada como A^G . A pseudoinversa é especialmente útil para matrizes que não são quadradas ou que têm determinantes iguais a zero, permitindo a solução de sistemas de equações lineares que são sobredeterminados ou subdeterminados. Calcular a inversa manualmente pode ser um processo tedioso e propenso a erros, especialmente para matrizes grandes. Felizmente, existem funções computacionais em várias linguagens de programação, como Python, R e Julia, que calculam tanto a inversa tradicional quanto a pseudoinversa de forma rápida e precisa, tornando desnecessário fazer esses cálculos manualmente.

Produto de Kronecker

É uma operação que toma duas matrizes A e B e produz uma matriz bloco maior, onde cada elemento a_{ij} de A é multiplicado pela matriz inteira B . Se A é uma matriz de dimensão $m \times n$ e B é uma matriz de dimensão $p \times q$, então o produto de Kronecker $A \otimes B$ resulta em uma matriz de dimensão $(mp) \times (nq)$. Esta operação é amplamente utilizada em álgebra linear, processamento de sinais e teoria da informação, pois preserva a estrutura de blocos e expande as matrizes de forma sistemática. Por exemplo, para as matrizes:

$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$, e $B = \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix}$, o produto de Kronecker $A \otimes B$ é

$$A \otimes B = \begin{bmatrix} 1 \cdot B & 2 \cdot B \\ 3 \cdot B & 4 \cdot B \end{bmatrix} = \begin{bmatrix} 1 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} & 2 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} \\ 3 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} & 4 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 0 & 5 & 0 & 10 \\ 6 & 7 & 12 & 14 \\ 0 & 15 & 0 & 20 \\ 18 & 21 & 24 & 28 \end{bmatrix}.$$

Exercícios.

1.1. Qual será a dimensão do produto das matrizes com as seguintes dimensões?

- a) $A_{3 \times 2} \times B_{2 \times 4} = AB_{___}$ b) $A_{5 \times 3} \times B_{3 \times 6} = AB_{___}$ c) $A_{4 \times 4} \times B_{4 \times 4} = AB_{___}$
d) $A_{3 \times 3} \times B_{2 \times 4} = AB_{___}$ e) $A_{5 \times 3} \times B_{6 \times 6} = AB_{___}$ f) $A_{4 \times 5} \times B_{4 \times 5} = AB_{___}$
g) $A_{2 \times 3} \times B_{3 \times 2} = AB_{___}$ h) $A_{6 \times 2} \times B_{2 \times 5} = AB_{___}$ i) $A_{6 \times 2} \times B_{2 \times 5} \times C_{5 \times 4} = ABC_{___}$

1.2. Calcule o produto das seguintes matrizes:

- a) $A = \begin{bmatrix} 4 & 5 \\ 4 & 2 \end{bmatrix}$, $B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, $AB = ?$ b) $A = \begin{bmatrix} 1 & 1 & 1 \\ 3 & 4 & 2 \end{bmatrix}$, $AA' = ?$
c) $A = [10 \ 11 \ 12]$, $B = \begin{bmatrix} 1 & 1 \\ 2 & 2 \\ 3 & 3 \end{bmatrix}$, $AB = ?$ d) $A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, $B = \begin{bmatrix} 7 & 4 & 3 \\ 4 & 2 & 1 \end{bmatrix}$, $C = \begin{bmatrix} 10 \\ 10 \\ 10 \end{bmatrix}$, $ABC = ?$
e) $A = \begin{bmatrix} 4 & 5 \\ 4 & 2 \end{bmatrix}$, $B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$, $A \otimes B = ?$

1.3. No software R, a função que realiza inversa de matrizes é a `solve()`. Já no Python a função é a `inv()`, dentro da biblioteca {`numPy`}. Utilize uma dessas duas funções para inverter as seguintes matrizes:

- a) $A = \begin{bmatrix} 4 & 6 \\ 3 & 2 \end{bmatrix}$ b) $B = \begin{bmatrix} 4 & 6 & 11 \\ 3 & 2 & 9 \\ 1 & 0 & 7 \end{bmatrix}$ c) $C = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$ d) $D = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$

1.4. O que é uma matriz singular? Alguma das matrizes da questão 1.3 é singular?

2. Modelos Lineares

Conceitos Básicos

Os modelos lineares são ferramentas estatísticas usadas para explicar a relação entre uma variável dependente e uma ou mais variáveis independentes. Aplicados em várias áreas devido à sua simplicidade, esses modelos podem ser simples, quadráticos ou múltiplos. O modelo linear simples envolve uma única variável independente, enquanto os modelos quadrático e múltiplo incorporam duas ou mais variáveis. A escolha do modelo depende da natureza das variáveis e da complexidade da relação entre elas. Vamos explorar os principais conceitos e a estimação desses modelos, destacando suas aplicações práticas e a interpretação dos resultados.

Forma Geral do Modelo Linear

A expressão geral de um modelo linear é dada por: $y = X\beta + \varepsilon$, onde: y é o vetor das observações da variável dependente; X é a matriz de design, que contém as observações das variáveis independentes; β é o vetor dos coeficientes desconhecidos (parâmetros do modelo) a serem estimados; ε é o vetor de erros aleatórios, que se assume ter média zero e variância constante $\varepsilon \sim N(0, \sigma^2)$.

Estimação dos Parâmetros

Na forma mais clássica, a estimação dos parâmetros β pode ser feita utilizando o método dos mínimos quadrados ordinários (MQO), que minimiza a soma dos quadrados dos resíduos (diferença entre os valores observados e os valores ajustados pelo modelo). A expressão para os valores estimados dos parâmetros ($\hat{\beta}$) é:

$$\hat{\beta} = (X'X)^{-1}X'y$$

Modelo Estimado

Após a estimação dos parâmetros, podemos escrever o modelo ajustado (ou estimado) como: $\hat{y} = X\hat{\beta}$, onde: \hat{y} é o vetor dos valores ajustados (ou preditos) da variável dependente; X é a matriz de design (ou matriz de dados) que contém as observações das variáveis independentes (preditores); e $\hat{\beta}$ são os coeficientes estimados. Lembre-se das operações de matrizes mostradas no capítulo anterior!

Matriz X (matriz de delineamento)

A matriz X é chamada de matriz de design e contém as observações das variáveis independentes (preditores) organizadas em colunas. No caso de um *modelo linear simples* com um intercepto, a matriz X pode ser representada como:

$$X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

Para um *modelo linear quadrático*, a matriz X incluiria um termo adicional para o quadrado da variável independente:

$$X = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix}$$

E para um *modelo linear multivariado*, por exemplo, com três variáveis independentes (x_1 , x_2 e x_3). Cada coluna da matriz X representa uma variável independente, e cada linha representa uma observação. Além disso, a primeira coluna é frequentemente composta por 1's, para incluir o intercepto no modelo.

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & x_{13} \\ 1 & x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & x_{n3} \end{bmatrix}$$

Um modelo linear multivariado pode ter tantas variáveis independentes (x) quanto necessário (x_1, x_2, \dots, x_m), limitado pelo número de observações, que é o número de dados em y ou o número de linhas em X (n), e pela necessidade de evitar colinearidade. A colinearidade pode dificultar a estimativa precisa dos coeficientes, exigindo técnicas como análise de componentes principais (PCA) ou seleção de variáveis.

Colinearidade é uma condição em que duas ou mais variáveis independentes em um modelo de regressão são altamente correlacionadas, dificultando a estimativa precisa dos coeficientes.

Exemplos de Modelos Lineares

1. **Modelo Linear Simples:** Relaciona uma única variável dependente y a uma única variável independente x :

$y = \beta_0 + \beta_1 x + \varepsilon$. Aqui, β_0 é o intercepto e β_1 é o coeficiente de inclinação.

2. **Modelo Linear Quadrático:** Inclui termos quadráticos para capturar curvaturas na relação:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

3. **Modelo Linear Múltiplo:** Relaciona uma variável dependente a múltiplas variáveis independentes:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

O Erros e Resíduos de um Modelo


Os resíduos de um modelo linear, são as diferenças entre os valores observados e os valores preditos pelo modelo. Matematicamente, o resíduo ε_i para a i -ésima observação é dado por $\varepsilon_i = y_i - \hat{y}_i$, onde y_i é o valor observado e \hat{y}_i é o valor predito pelo modelo. Os resíduos são fundamentais na análise de regressão, pois indicam a precisão e a eficácia do modelo. Analisá-los pode revelar heterocedasticidade, autocorrelação ou outliers, apontando problemas a serem corrigidos. Tecnicamente, "resíduo" é a diferença entre o valor observado e o predito pelo modelo ajustado, enquanto "erro" é a diferença entre o valor observado e o verdadeiro desconhecido, embora esses termos sejam frequentemente confundidos na literatura científica.

Exercícios:

2.1. Calcule \hat{y}_i para os dois modelos de regressão linear abaixo.

Dados:

x	y
1	7
2	24
3	20
4	30
5	23




a) Modelo de regressão linear simples:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

$$y = 9,4 + 3,8 x + \varepsilon$$

$$\hat{y}_i = 9,4 + 3,8 x_i$$



b) Modelo de regressão linear quadrática

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

$$y = -7,6 + 18,37 x - 2,43 x^2 + \varepsilon$$



$$\hat{y}_i = -7,6 + 18,37 x_i - 2,43 x_i^2$$

2.2. Para o enunciado acima (questão 2.1), obtenha \hat{y} , por meio de multiplicação matricial, fazendo-se $\hat{y} = X\hat{\beta}$. Além disso, calcule os resíduos dos modelos. Faça tanto para o item 'a' quanto para o 'b'.

2.3. Os parâmetros ajustados da regressão multivariada $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + e$, são:

$\hat{\beta}_0 = 52,37$; $\hat{\beta}_1 = 9,38$; $\hat{\beta}_2 = 11,32$; $\hat{\beta}_3 = -4,37$; e $\hat{\beta}_4 = 6,11$, respectivamente. Mostre a matriz de delineamento X para esse caso, e calcule \hat{y}_i com os dados abaixo.

y	x_1	x_2	x_3	x_4
54.5	0.9	-1.0	-0.2	0.3
53.3	-0.5	0.4	-0.1	-0.5
53.9	1.0	-0.7	1.3	1.1
52.0	1.2	-1.0	0.2	0.0
47.7	-0.7	-1.0	-2.2	0.4
57.4	-1.2	0.9	1.1	2.1
65.7	-0.7	1.7	0.4	-0.3
62.8	1.0	1.2	0.2	-0.8
25.4	-1.4	-0.6	-1.0	-1.0
52.2	0.3	0.2	0.2	-1.2



Os dois gráficos mostrados contêm as respostas em "Valores Estimados". Use-os para conferir seus resultados. O gráfico da esquerda mostra a relação entre y observado e \hat{y} obtido por $X\hat{\beta}$. E, o gráfico da direita mostra os valores de $\hat{y} = X\hat{\beta}$ em função da média de todos os x 's.

2.4. Calcule e interprete os resíduos para o modelo da questão 2.3.